C언어 소스코드 분석 (x86 Assembly)

홍정완

(HTTPS://GITHUB.COM/JUNG9928)

목차

1. C언어로 작성된 소스코드 분석 (x86 Assembly).
2. Intel Instruction Architecture의 특징

목적

1. c언어 코드 분석을 통해 기존에 알고있던 MASM 지식 활용 및 정리.

2. x86 Assembly에 대한 설명을 상세하게 하려는 목적이 아닌 이미 알고 있다는 가정 하에,

C언어 코드가 어떻게 x86 Assembly 언어로 변환되고 Memory에는 어떤 값이 저장되는지를 관찰하는 것이 주목적입니다.

3. 기존의 MIPS나 ARM 아키텍처를 사용하는 CORTEX-M 시리즈 등 RISC 방식의 인스트럭션과의 차이점도 복기하자는 목적으로 작성하였습니다.

코드 분석

```c
#include <stdio.h>

int main()
{
    int a, b, sum;
    scanf("%d %d", &a, &b);

    sum = a + b;

    printf("%d", sum);

    return 0;
}
```

- 왼쪽의 소스코드는 간단한 덧셈을 수행하는 소스코드이다.

- 코드를 line by line으로 분석해보자.

```
1   #include <stdio.h>
2
3   int main()
4   {
5       int a, b, sum;
6       a = 3;
7       b = 4;
8
9       sum = a + b;
10
11      printf("%d", sum);
12
13      return 0;
14  }
```

```
#include <stdio.h>

int main()
{
00D21810  push        ebp
00D21811  mov         ebp,esp
00D21813  sub         esp,0E4h
00D21819  push        ebx
00D2181A  push        esi
00D2181B  push        edi
00D2181C  lea         edi,[ebp-0E4h]
00D21822  mov         ecx,39h
00D21827  mov         eax,0CCCCCCCCh
00D2182C  rep stos    dword ptr es:[edi]
00D2182E  mov         ecx,offset _D9812314_dfs_bfs 연습장₩dfs_bfs 연습장₩소스코드분석@c (0D2C003h)
00D21833  call        @__CheckForDebuggerJustMyCode@4 (0D21217h)
```

- main 함수의 entry point.
- main 함수의 STACK FRAME이 생성됨.

- main 함수의 stack frame이 생성됨. 현재 stack pointe의 값을 base pointer 값으로 초기화하여 해당 함수의 인자 값을 저장하고 접근하기 위한 기준점(위치)으로 사용하고, stack pointer(esp)는 이동시켜가며 지역변수를 stack frame에 저장.
- ebx, esi, edi, ecx, eax 범용 레지스터들은 main 함수 호출 시, 필요한 stack을 셋업하고 관련 레지스터들을 보존하는 작업을 위해 존재.

- main 뿐만 아니라 모든 함수들에 대한 assembly 코드 초입에 존재한다.

main 함수의 stack frame 영역

```
0x00D21810  55 8b ec 81 ec e4 00 00 00 53 56 57 8d bd 1c ff ff ff b9 39 00 00
0x00D21826  00 b8 cc cc cc cc f3 ab b9 03 c0 d2 00 e8 df f9 ff ff c7 45 f8 03
0x00D2183C  00 00 00 c7 45 ec 04 00 00 00 8b 45 f8 03 45 ec 89 45 e0 8b 45 e0
0x00D21852  50 68 30 7b d2 00 e8 e9 f7 ff ff 83 c4 08 33 c0 5f 5e 5b 81 c4 e4
```

- visual studio에서 dOebugging 기능을 수행하기 위해 제공하는 함수 . 맹글링으로 @__CheckForDebuggerJustMyCode로 사용됨.

```
레지스터
EAX = 008B6EF0 EBX = 005DB000 ECX = 00000001
EDX = 008BD718 ESI = 00D21339 EDI = 00D21339
EIP = 00D21810 ESP = 006FF9CC EBP = 006FF9E8
EFL = 00000206
```

```
1   #include <stdio.h>
2
3   int main()
4   {
5       int a, b, sum;
6       a = 3;  경과 시간 1ms 이하
7       b = 4;
8
9       sum = a + b;
10
11      printf("%d", sum);
12
13      return 0;
14  }
```

- 단순 변수 선언문에는 break point가 걸리지 않는다.
  그 이유는, 컴파일러가 컴파일 시, 변수 선언의 경우 메모리를 할당하는 것이 아닌 임의의 메모리 공간을 선정해서 사용할 것이라고 예약한 꼴이기 때문.

그렇기에, 위의 어셈블리 코드를 보면 변수 선언문 부분에 instruction이 생성되지 않은 것을 확인할 수 있으며 그렇기에 break point를 걸 수 없는 것이고 실행흐름이 바로 변수 초기화 부분으로 넘어간 것을 확인할 수 있다.

- 변수에 값을 할당하는 부분인 a = 3;에서는 그 이전 변수 선언문에서 컴파일러가 선정(예약)한 메모리 공간에 값을 저장하게 된다.

```
    int a, b, sum;
    a = 3;
00D21838  mov         dword ptr [a],3
    b = 4;
00D2183F  mov         dword ptr [b],4
```

EIP 는 다음에 실행할 instruction의 주소가 저장된 Register.
현재 실행될 instruction인 “mov dword ptr [a], 3”의 주소를 가지고 있음.

```
레지스터
EAX = 00D2C003 EBX = 0050B000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D21838 ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000246

0x006FF9C0 = CCCCCCCC
```

mov는 메모리 or 레지스터에 값을 옮기기 위한 instruction이며,
지정된 오퍼랜드인 dword ptr [a]와 3 중에서 오른쪽 오퍼랜드 값(3)을 왼쪽 오퍼랜드(dword ptr [a])로 옮기는 역할을 수행.

dword ptr은 우리가 C언어에서 사용하는 int, double, long과 같이 메모리 사이즈를 지정하는 directive임. dword는 32비트 크기 지정.

```c
#include <stdio.h>

int main()
{
    int a, b, sum;
    a = 3;
    b = 4;

    sum = a + b;

    printf("%d", sum);

    return 0;
}
```

- a와 b를 더한 결과 값을 변수 sum에 저장하는 과정

메모리 2

주소: 0x006FF9C0

0x006FF9C0 03 00 00 00

레지스터

EAX = 00D2C003 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D21846 ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000246

0x006FF9C0 = 00000003

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax
```

메모리 2

주소: 0x006FF9B4

0x006FF9B4 04 00 00 00

레지스터

EAX = 00000003 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D21849 ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000246

0x006FF9B4 = 00000004

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax
```

- add는 메모리 오퍼랜드 + 메모리 오퍼랜드 or
메모리 오퍼랜드 + 레지스터 or 레지스터 + 메모리 오퍼랜드
메모리 오퍼랜드 + 상수를 수행하는 어셈블리어이다.

이전에 초기화한 변수 a, b를 더하기 위해 누산기 역할을 수행하는 레지스터인 eax를 사용한다.
eax 레지스터는 모든 산술연산에서 사용되며, 가장 많이 사용되는 범용 레지스터이다.

메모리 2

주소: &sum

0x006FF9A8 07 00 00 00

레지스터

EAX = 00000007 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D2184F ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000202

0x006FF9A8 = 00000007

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax

    printf("%d", sum);
00D2184F  mov         eax,dword ptr [sum]
00D21852  push        eax
```

```c
#include <stdio.h>

int main()
{
    int a, b, sum;
    a = 3;
    b = 4;

    sum = a + b;

    printf("%d", sum);

    return 0;
}
```

- a와 b를 더한 결과 값을 변수 sum에 저장하는 과정

메모리 2

주소: 0x006FF9C0

0x006FF9C0 03 00 00 00

레지스터

EAX = 00D2C003 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D21846 ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000246

0x006FF9C0 = 00000003

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax
```

메모리 2

주소: 0x006FF9B4

0x006FF9B4 04 00 00 00

레지스터

EAX = 00000003 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D21849 ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000246

0x006FF9B4 = 00000004

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax
```

- add는 메모리 오퍼랜드 + 메모리 오퍼랜드 or
메모리 오퍼랜드 + 레지스터 or 레지스터 + 메모리 오퍼랜드
메모리 오퍼랜드 + 상수를 수행하는 어셈블리어이다.

이전에 초기화한 변수 a, b를 더하기 위해 누산기 역할을 수행하는 레지스터인 eax를 사용한다.
eax 레지스터는 모든 산술연산에서 사용되며, 가장 많이 사용되는 범용 레지스터이다.

메모리 2

주소: &sum

0x006FF9A8 07 00 00 00

레지스터

EAX = 00000007 EBX = 005DB000 ECX = 00D2C003
EDX = 00000001 ESI = 00D21339 EDI = 006FF9C8
EIP = 00D2184F ESP = 006FF8D8 EBP = 006FF9C8
EFL = 00000202

0x006FF9A8 = 00000007

```
    sum = a + b;
00D21846  mov         eax,dword ptr [a]
00D21849  add         eax,dword ptr [b]
00D2184C  mov         dword ptr [sum],eax

    printf("%d", sum);
00D2184F  mov         eax,dword ptr [sum]
00D21852  push        eax
```

```c
#include <stdio.h>

int main()
{
    int a, b, sum;
    a = 3;
    b = 4;

    sum = a + b;

    printf("%d", sum);

    return 0;
}
```

- printf함수가 호출되면서 printf 함수 고유의 stack frame이 생성된다.

```c
#include <stdio.h>

int main()
{
    int a, b, sum;
    a = 3;
    b = 4;

    sum = a + b;

    printf("%d", sum);

    return 0;
}
```

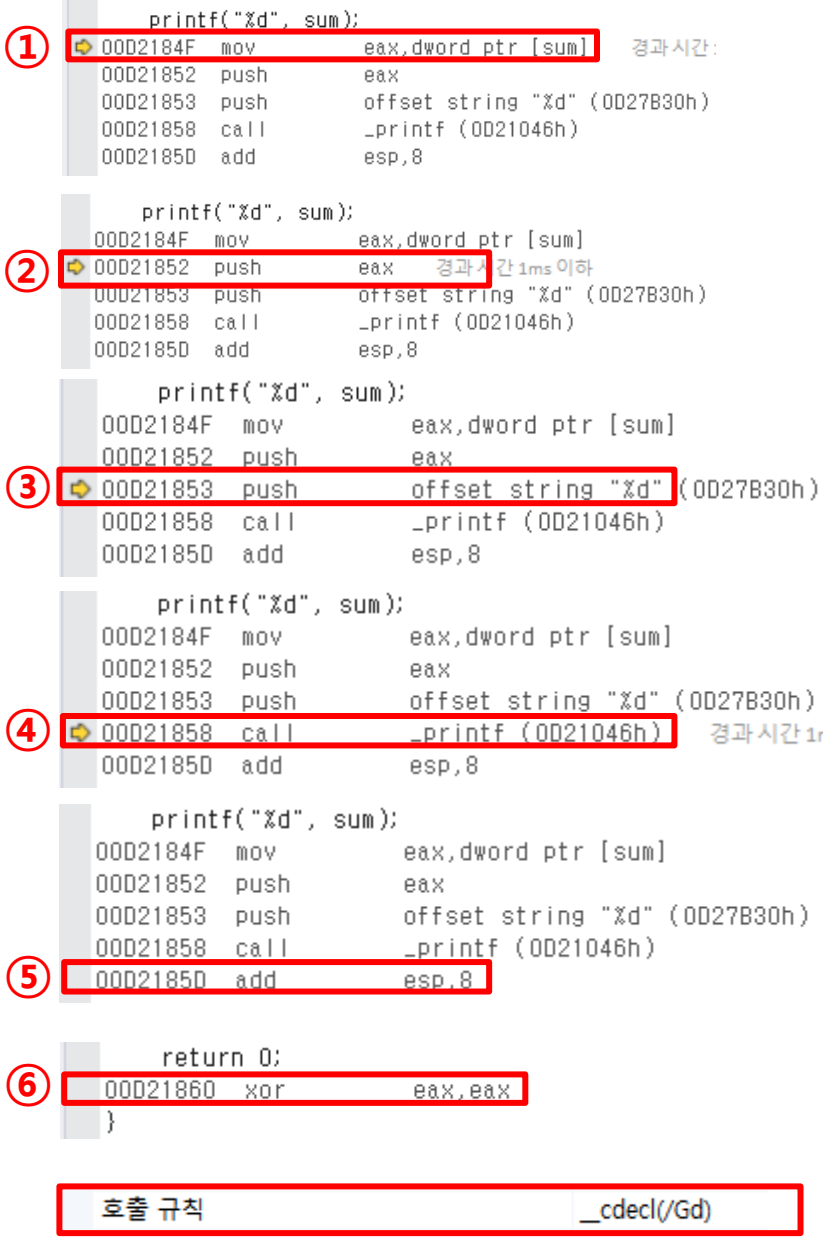

1) printf의 stackframe에 인자 값인 sum을 저장하기 위해 eax 레지스터로 데이터를 이동.

2) stack frame에 sum 값이 저장된 eax 레지스터 값을 push

3) 출력 값을 저장할 공간을 stack에 push.

4) 실제 printf함수를 구성하는 _printf 함수를 호출.

5) printf 동작을 마친 후, esp에 할당된 메모리 크기 값을 더하여 stack frame을 해제. 이것을 통해 cdecl 호출 규약을 사용한다는 것을 알 수 있음.

   만약 ret 8 이었다면 stdcall 호출 규약을 사용한 것.

6) main 함수의 stack frame이 소멸되면서 main 함수 종료.

   xor 연산을 통해 return 값이 0인지 아닌지 판별.

```
int main()
{
00661920  push        ebp
00661921  mov         ebp,esp
00661923  sub         esp,0E4h
00661929  push        ebx
0066192A  push        esi
0066192B  push        edi     경과시간 1ms 이하
0066192C  lea         edi,[ebp-0E4h]
00661932  mov         ecx,39h
00661937  mov         eax,0CCCCCCCCh
0066193C  rep stos    dword ptr es:[edi]
0066193E  mov         ecx,offset _D9812314_dfs_bfs 연습장₩dfs_bfs 연습장₩소스코드분석@c (066C003h)
00661943  call        @__CheckForDebuggerJustMyCode@4 (066121Ch)
    int a, b, sum;
    scanf("%d %d", &a, &b);
00661948  lea         eax,[b]
0066194B  push        eax
0066194C  lea         ecx,[a]
0066194F  push        ecx
00661950  push        offset string "%d %d" (0667B30h)
00661955  call        _scanf (066109Bh)
0066195A  add         esp,0Ch

    sum = a + b;
0066195D  mov         eax,dword ptr [a]
00661960  add         eax,dword ptr [b]
00661963  mov         dword ptr [sum],eax

    printf("%d", sum);
00661966  mov         eax,dword ptr [sum]
00661969  push        eax
0066196A  push        offset string "%d" (0667B38h)
0066196F  call        _printf (0661046h)
00661974  add         esp,8

    return 0;
00661977  xor         eax,eax
}
```

왼쪽은 디스 어셈블리한 결과임.

빨간 박스에 있는 숫자들은 각 x86 명령어들의 instruction 값을 의미함.

보면 불규칙적으로 값이 늘어가는 것을 볼 수 있는데 이것이 Intel Instruction Architecture의 특징임.

Intel은 Instruction set의 초기 설계 방식을 CISC로 했기 때문에 각각의 instruction들의 크기가 다르다.

그래서 instruction의 주소가 규칙적으로 증가하지 않는 것.

그러나 시간이 지남에 따라 RISC 방식과 합쳐 CISC + RISC 방식을 도입하였고 이것은 하위 호환성을 고려하여 CISC 방식을 완전히 버리지 못한 것 같다.

이러한 원초적으로 한계가 있을 수 밖에 없는 CISC 방식을 개선하기 위해 슈퍼스칼라 방식 또한 도입하여 성능 개선을 계속해서 해오고 있으며

이것이 MIPS와 ARM에서 사용되는 RISC 방식과는 대비되는 Intel Instruction Architecture의 특징이다

감사합니다.

출처 : https://github.com/Jung9928